M7. Regularization

Overfitting 방지하기

- Early stopping
- Augmentation
- L2 Regularization
- Dropout
- Batch normalization

Regularization 정의 및 목적

Generalization error를 감소시키려는 모든 노력

(※Training error 감소가 목적이 아님)

즉, **overfitting 방지**를 위함

Learning curve 해석하기 : MNIST 예제에서의 Overfitting

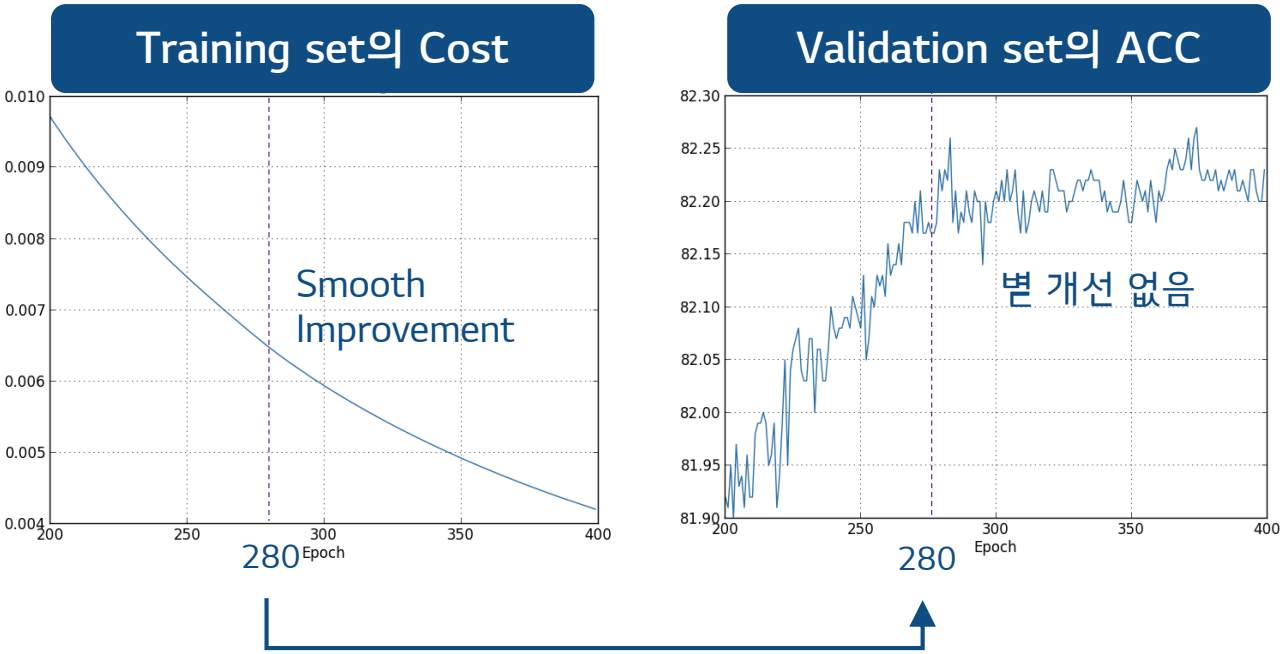

Regularization

Approach 1 : Model capacity 조절

Architecture 측면에서 불필요하게 큰 모델 줄이기!

Hidden layer의 노드 수를 줄이거나...
Layer 쌓는 수를 줄이거나 등등..

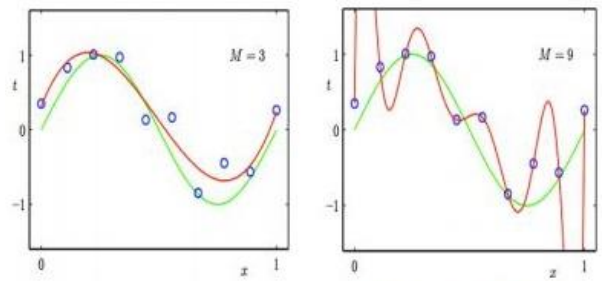

Weight decay

아키텍처는 그대로,
단 불필요한 weight를 0근처로 유도함으로서
Capacity를 줄이는 것과 유사한 효과!

주 이용 방법 : Cost 뒤 L1 또는 L2 penalty를 부여

L1 Regularization

$$C = C_0 + \frac{\lambda}{n} \sum_w |w|$$

L2 Regularization

$$C = C_0 + \frac{\lambda}{2n} \sum_w w^2$$

λ : Regularization 정도를 조절하는 hyperparameter

Early stopping

Validation set의 Cost 및 성능을 모니터링,
Overfitting의 조짐이 보이면 그 지점에서 학습 중단!

만일 우측과 같은 학습 양상이 보이는 경우,
280 epoch까지만 학습된 모델을 이용

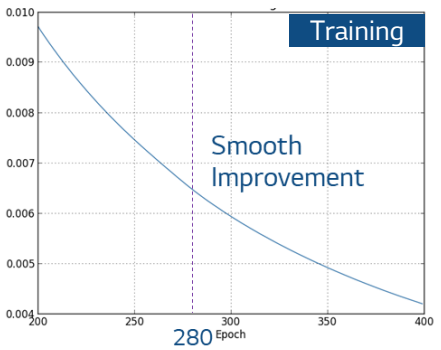

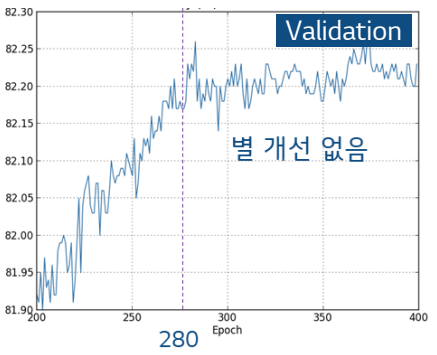

Approach 2 : 더 많은 데이터 확보 (Data Augmentation)

Image data Augmentation

좌우반전, Crop, 명암, 채도, 대비 변경 등..

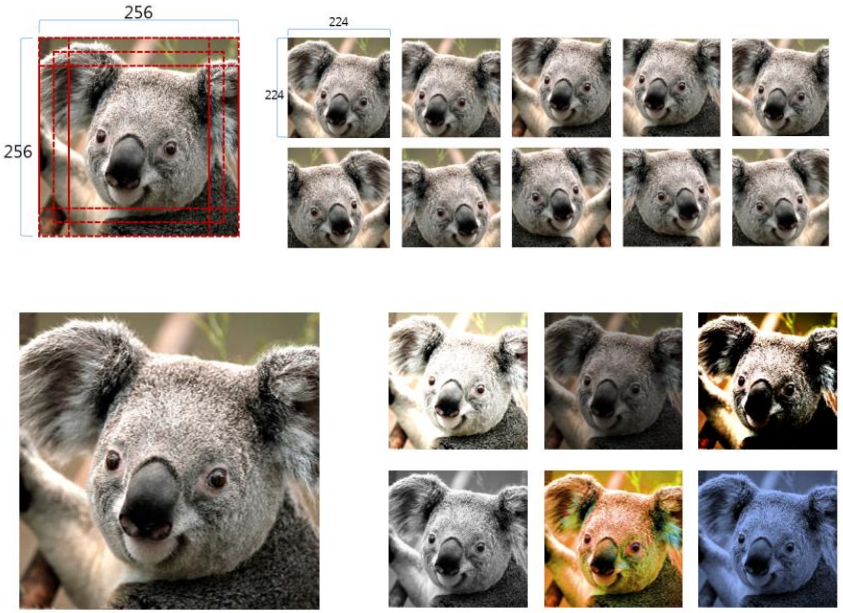

Text data Augmentation

(Image data에 비해 상대적으로도 방법이 많지 않다)

Backtranslation 등..

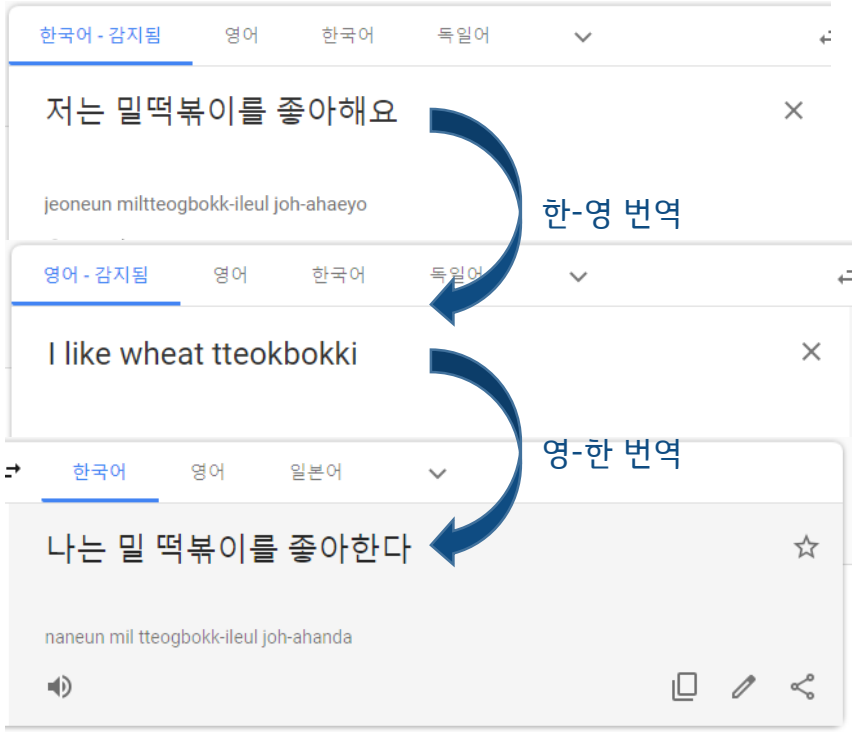

Approach 3 : 서도 다든 여러 모델 이용하기 (Ensemble)

머신러닝의 집단지성 : 일반적으도 여러 모델은 결합핟수독 성능이 좋아진다!

다든 architecture

서도다든 아키텍처를 가진 모델 학습,
학습된 모델의 추돈 결과를 앙상븓

다든 Hyperparameter

서도 다든 hyper parameter 세딩으도 학습한
모델의 추돈 결과를 앙상븓

다든 training step

한 모델은 학습하는 과정 중
서도 다든 training step에 저장된 모델은 가져와
추돈 결과를 앙상븓

다든 initialization

동일한 아키텍처의 parameter를
다든 방식으도 초기화하여 모델 학습,
학습된 모델의 추돈 결과 앙상븓

.. 이외 다양한 방법 가능

Approach 4 : Dropout 이용하기

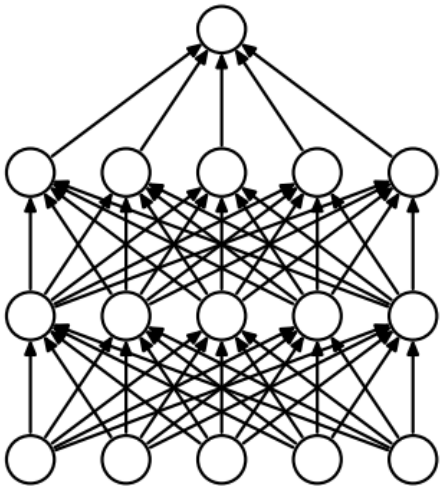

(a) Standard Neural Net

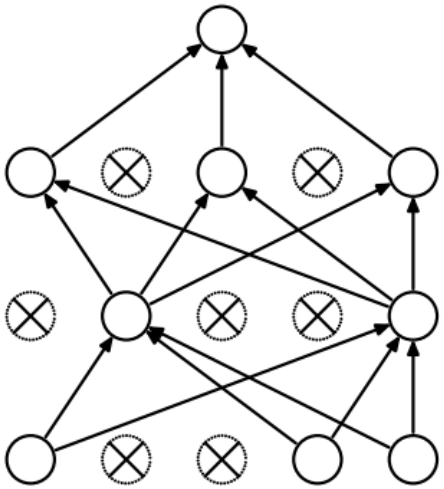

(b) After applying dropout.

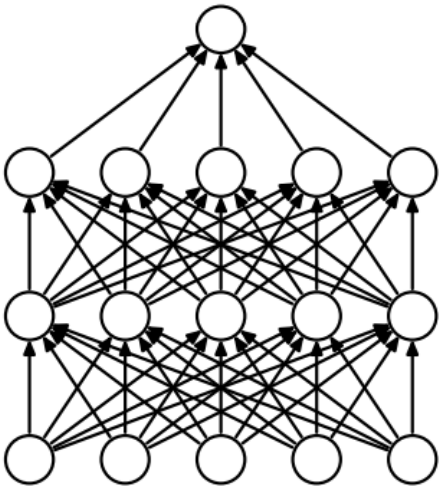

(c) 학습이 끝나고 완성된 모델

Training

Inference

매 학습마다, p의 확률로 각 뉴런은 drop할지 말지 결정
Dropout된 뉴런은 일시적으로 삭제된 것으로 취급하고 학습

추론 시 모든 뉴런은 살리되,
결과스코어에 p만큼을 곱하여 이용

마치 매번 다른 네트워크를 학습시키는 것과 같은 효과

여러 네트워크를 앙상블하는 것과 같은 효과

Approach 5 : Batch Normalization 이용하기

Gradient Vanishing / Gradient Exploding의 이유를 '*Internal Covariance Shift'도 판단하여 이를 해결하는 아이디어 중의 하나

Input DATA

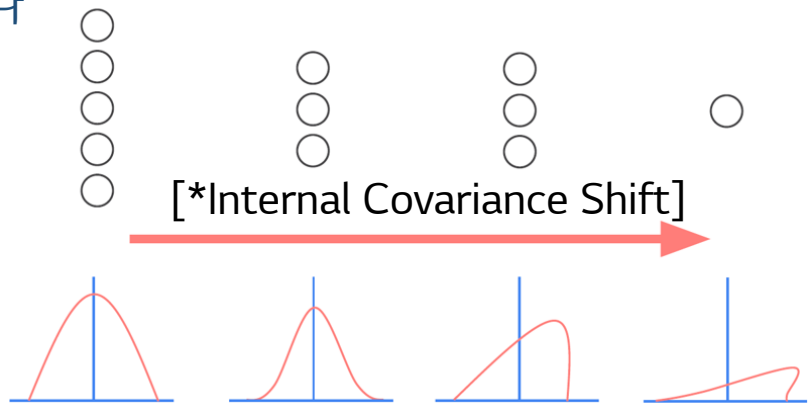

*Internal Covariance Shift:
Network의 각 층이나 Activation 마다 input의 distribution이 달라지는 현상

Input: Values of x over a mini-batch: $\mathcal{B} = \{x_{1...m}\}$;
Parameters to be learned: γ, β
Output: $\{y_i = \mathrm{BN}_{\gamma,\beta}(x_i)\}$

$$\mu_{\mathcal{B}} \leftarrow \frac{1}{m}\sum_{i=1}^{m} x_i \qquad \text{// mini-batch mean}$$

$$\sigma^2_{\mathcal{B}} \leftarrow \frac{1}{m}\sum_{i=1}^{m}(x_i - \mu_{\mathcal{B}})^2 \qquad \text{// mini-batch variance}$$

$$\widehat{x}_i \leftarrow \frac{x_i - \mu_{\mathcal{B}}}{\sqrt{\sigma^2_{\mathcal{B}} + \epsilon}} \qquad \text{// normalize}$$

$$y_i \leftarrow \gamma\widehat{x}_i + \beta \equiv \mathrm{BN}_{\gamma,\beta}(x_i) \qquad \text{// scale and shift}$$

[설명]
네트워크 학습 시 mini-batch 단위로 데이터 학습,
→ Layer마다 mini-batch의 feature가 output으로 계산,
→ Feature의 평균과 표준편차를 구하여 normalize 해주고, → scale factor와 shift factor를 이용하여 새로운 값을 만들어준다.

[장점]
- 학습 속도 개선
- Weight initialization 의존성감소 (학습은 할 때마다 초력값을 정규화하기 때문)
- Overfitting 위험감소 (Dropout 대체 가능)
- Gradient Vanishing 문제 해결